

PDD_STAT — Руководство пользователя

Версия: 1.0

Разработчик: П. Демешко

Язык интерфейса: английский (метки, выводы результатов — на английском)

Содержание

1. Обзор системы
2. Установка и запуск
3. Управление проектами и данными
 4. 3.1. Создание проекта и загрузка данных
 5. 3.2. Очистка данных
 6. 3.3. Управление переменными
 7. 3.4. Контекст проекта (описание, цель)
8. Интерфейс
 9. 4.1. Левая панель — Project Manager
 10. 4.2. Рабочая область
 11. 4.3. Правая панель — Variables
12. Шаблоны статистического анализа
 13. 5.1. Categorical Comparison — Сравнение категориальных переменных
 14. 5.2. Numeric Comparison — Сравнение числовых переменных
 15. 5.3. Correlation Analysis — Корреляционный анализ
 16. 5.4. Spline Analysis — Сплайн-анализ
 17. 5.5. Descriptive Statistics — Описательная статистика
 18. 5.6. Violin Plots — Скрипичные диаграммы
 19. 5.7. ANOVA / Kruskal-Wallis — Дисперсионный анализ
 20. 5.8. Chart Builder — Построитель графиков

- 21. 5.9. Cox Regression — Регрессия Кокса
 - 22. 5.10. Logistic Regression — Логистическая регрессия
 - 23. 5.11. Logistic LASSO — LASSO-регрессия
 - 24. 5.12. Random Forest — Случайный лес
 - 25. 5.13. Kaplan-Meier — Кривые Каплана–Мейера
 - 26. 5.14. ROC Analysis — ROC-анализ
 - 27. 5.15. Model Evaluation (Binary) — Оценка бинарной модели
 - 28. 5.16. Survival Prediction Evaluation — Оценка прогнозов выживаемости
 - 29. 5.17. Diagnostic Accuracy — Диагностическая точность
 - 30. 5.18. Agreement Analysis — Анализ согласия
 - 31. 5.19. Individual Prediction — Индивидуальный прогноз
 - 32. [AI Chat](#)
 - 33. 6.1. Настройки AI
 - 34. 6.2. Режимы: Assistant и Coder
 - 35. [Отчёты](#)
 - 36. 7.1. Обычный DOCX-отчёт
 - 37. 7.2. AI-отчёт
 - 38. [Режим Code Editor](#)
 - 39. [История анализа \(Chain\)](#)
 - 40. [Клавиатурные сочетания и советы](#)
-

1. Обзор системы

PDD_STAT — веб-приложение для статистического анализа медицинских и клинических данных. Система предоставляет:

- **22 шаблона** статистического анализа (от описательной статистики до регрессионных моделей и анализа выживаемости)
- **AI-ассистента** на базе Ollama (локально) или Groq (облачный API)
- **Генерацию отчётов** в формате DOCX (обычный и AI-сгенерированный)
- **Редактор кода** для произвольного Python-анализа

- **Визуализацию:** графики matplotlib, SHAP, DCA, калибровочные кривые

Ключевые возможности

- **Все выводы — на английском языке** (метрики, таблицы, подписи графиков)
- **Защита от статистических ошибок:** проверка пропорциональных рисков (Schoenfeld), мультиколлинеарности (VIF), нормальности, гомогенности дисперсий, калибровки (Hosmer-Lemeshow)
- **Коррекция на множественные сравнения** (Бонферрони) в попарных тестах
- **Стратифицированный анализ** для выживаемости
- **Пошаговый отбор** (stepwise) предикторов с контролем p-уровня
- **DCA** (Decision Curve Analysis) и **калибровочные кривые** для регрессионных моделей
- **Bootstrap** для доверительных интервалов метрик
- **SHAP** для интерпретации моделей Random Forest

2. Установка и запуск

Требования

Компонент	Версия
Python	≥ 3.11
pip	≥ 21.0

Быстрый старт (один клик)

macOS:

```
./setup_mac.command && ./start_backend.command
```

Windows:

```
setup.bat  
start.bat
```

Скрипты автоматически находят Python 3.11+, создают виртуальное окружение, устанавливают зависимости и запускают сервер.

Ручная установка (альтернатива)

```
cd app/backend
pip install -r requirements.txt
python -m uvicorn app.main:app --host 127.0.0.1
--port 8000
```

Откройте браузер по адресу: **http://127.0.0.1:8000**

Фронтенд не требует отдельной сборки — сервер раздаёт статические файлы (`app/frontend/`) автоматически.

3. Управление проектами и данными

3.1. Создание проекта и загрузка данных

1. Нажмите "**Create Project**" (левая панель).
2. Введите название проекта (латиница или кириллица).
3. Выберите файл с данными:
4. Поддерживаемые форматы: `.xlsx` , `.xls` , `.csv`
5. Нажмите "**Create**".
6. После загрузки появится окно **Cleaning Recommendations** (см. раздел 3.2).

Повторная загрузка в существующий проект: нажмите на название проекта левой кнопкой — откроется диалог выбора файла.

3.2. Очистка данных

При загрузке данных система автоматически анализирует каждую колонку и предлагает план очистки:

Удаляемые колонки

Правило	Условие	Уровень
HIGH_MISSING	>30% пропущенных значений	Жёсткое
MODERATE_MISSING	20–30% пропущенных	Мягкое
CONSTANT	только 1 уникальное значение	Жёсткое
IDENTIFIER	все значения уникальны (n>10)	Жёсткое
TECHNICAL	имя начинается с INFO_, CHECK_, PARAMS_ и т.д.	Жёсткое

Импутация

Остальные колонки с пропусками: - **Числовые** → заполняются **медианой** - **Категориальные/строковые** → заполняются **модой**

Кнопки: - "Apply Cleaning" — применить очистку - "Skip (Keep as is)" — сохранить данные как есть

После очистки данные сохраняются в `state/project_data.parquet` (сжатие snappy).

3.3. Управление переменными

Правая панель → вкладка "Columns":

- **Поиск** по названию переменной
- **Тип переменной** отображается бейджем:
 - `num` — числовая
 - `cat` — категориальная
 - `bin` — бинарная
 - `str` — строковая
- **Действия с переменной:**
 -  — переименовать
 -  — удалить из датасета
 -  — открыть окно меток (Label):
 - **Chart Name** — отображаемое имя на графиках

- **Value Labels** — метки значений (например, 0 = Нет, 1 = Да)

Быстрый выбор переменной: клик по имени переменной присваивает её активному полю в карточке анализа (поле подсвечивается цветом).

3.4. Контекст проекта (описание, цель)

Кнопка  на элементе проекта → **Project Context**:

- **Description** — описание проекта (используется AI для контекста)
- **Research Aim** — цель исследования
- **Notes** — дополнительные заметки

Контекст автоматически включается в системный промпт AI-ассистента и в AI-отчёты.

4. Интерфейс

4.1. Левая панель — Project Manager

Элемент	Описание
+ Create Project	Создать новый проект
Список проектов	Имена проектов. Клик — открыть/загрузить данные.  — контекст. X — удалить
AI Settings	Настройки AI-ассистента
◀ ▶	Свернуть/развернуть панель

4.2. Рабочая область

Центральная область — контейнер для карточек анализа (см. раздел 5).

Меню выбора шаблонов (верхняя панель):

Меню	Шаблоны
Basic Stats ▼	Categorical, Numeric, Correlation, Spline, Descriptive, Violin, ANOVA, Chart Builder
Regression ▼	Cox, Logistic, LASSO, Random Forest
Survival ▼	Kaplan-Meier
Evaluation ▼	Model Evaluation (Binary), Survival Eval, ROC, Diagnostic Accuracy, Agreement
Prediction ▼	Individual Prediction

Кнопки: - **AI Chat** — открыть чат с AI-ассистентом - **Code**
— перейти в режим редактора кода -  —
переключение светлой/тёмной темы

4.3. Правая панель — Variables

Вкладка	Содержимое
Columns	Список переменных с поиском, типами, редактированием
Reports	Генерация отчётов DOCX
Chain	История выполненных анализов

5. Шаблоны статистического анализа

5.1. Categorical Comparison

Метод: χ^2 -тест / Точный тест Фишера / Монте-Карло

Параметры: | Поле | Описание | |-----|-----| | col1 |
Первая категориальная переменная (строки таблицы) | |
col2 | Вторая категориальная переменная (столбцы
таблицы) |

Логика выбора теста: 1. Если все ожидаемые частоты ≥ 5
→ χ^2 -тест 2. Если низкие ожидаемые И таблица 2x2 →
Точный тест Фишера 3. Иначе → **Монте-Карло** (10 000
итераций)

Выводимые метрики:

Метрика	Описание
chi2	Статистика χ^2
p_value	Уровень значимости
df	Число степеней свободы
min_expected_frequency	Минимальная ожидаемая частота
all_expected_ge5	Все ожидаемые ≥ 5 ?
odds_ratio	Отношение шансов (только для Fisher, 2x2)
significant	$p < 0.05$

Интерпретация p-value: - $p < 0.05$ — есть статистически значимая связь между переменными - $p \geq 0.05$ — нет оснований отвергать гипотезу о независимости

5.2. Numeric Comparison

Метод: t-тест (независимый) / ANOVA (параметрический) или U-тест Манна–Уитни / H-тест Краскела–Уоллиса (непараметрический)

Параметры: | Поле | Описание | |-----|-----| | value |
Числовая зависимая переменная | | group |
Категориальная группирующая переменная |

Логика выбора теста: - Если **нормальность** (Shapiro-Wilk) И **гомогенность дисперсий** (Levene): - 2 группы → **t-тест** + d Коэна - >2 групп → **ANOVA** + η^2 - Иначе: - 2 группы → **U-тест Манна–Уитни** - >2 групп → **H-тест Краскела–Уоллиса**

Выводимые метрики:

Метрика	Описание
test_name	Название применённого теста
statistic	Значение тестовой статистики
p_value	Уровень значимости
cohens_d	d Козна (для t-теста) — мера эффекта
normality	Результаты теста Шапиро–Уилка по группам
equal_var	Гомогенность дисперсий (Levene)
descriptive_stats	Описательные статистики по группам (n, median, Q1, Q3)

Графики: Voxplot + барплот (среднее ± SD), 2 панели.

5.3. Correlation Analysis

Метод: Корреляция Пирсона (параметрическая) или Спирмена (ранговая)

Параметры: | Поле | Описание | |-----|-----| |
predictors | Выбор нескольких переменных | | method |
Pearson (для нормальных данных) или Spearman (для
любых) | | threshold | Порог |r|: 0.3, 0.5 (по умолч.), 0.7 |

Выводимые метрики:

Метрика	Описание
method	Метод корреляции
n_variables	Количество переменных
n_strong_pairs	Пар с
strongest_r	Максимальный
strongest_pair	Пара с макс.
pairs	Список сильных пар: var1, var2, r, скорректированный p (Бонферрони)

p-value корректируется по методу Бонферрони (умножается на число всех попарных тестов), что контролирует семейную ошибку первого рода (FWER).

Графики: Тепловая карта корреляционной матрицы (нижний треугольник).

5.4. Spline Analysis

Метод: Линейный сплайн-анализ в рамках Cox-регрессии или логистической регрессии

Параметры: | Поле | Описание | |-----|-----| | `variable` | Переменная для сплайна | | `target` | (для логистики) Бинарный исход | | `time + event` | (для Cox) Время + событие | | `covariates` | Ковариаты для коррекции | | `knots` | Расположение узлов: Median, Quartiles, Custom + число |

Выводимые метрики:

Метрика	Описание
<code>model_type</code>	<code>spline_cox</code> или <code>spline_logistic</code>
<code>knots</code>	Позиции узлов сплайна
<code>nonlinear_p</code>	p-value теста нелинейности — проверяет, значимо ли отклонение от линейности
<code>significant_nonlinear</code>	$p < 0.05 \rightarrow$ есть нелинейный эффект

Графики: Log-HR / Log-OR vs переменная с узлами (левая панель) + гистограмма переменной с узлами (правая панель).

5.5. Descriptive Statistics

Метод: Описательные статистики + тест Шапиро–Уилка

Параметры: | Поле/Опция | Описание | |-----|-----| | `covariates` | Переменные (пусто = все числовые) | |

`Include histograms` | Гистограммы для каждой переменной |

Выводимые метрики: - N, Mean, Median, Std, Min, Max, Q1, Q3 - Skewness (асимметрия), Kurtosis (эксцесс) - Missing count (количество пропусков) - Outlier count (количество выбросов по методу IQR — за пределы $Q1-1.5 \times IQR$ / $Q3+1.5 \times IQR$) - Shapiro-Wilk W и p-value (нормальность; $p < 0.05$ = распределение отличается от нормального)

5.6. Violin Plots

Метод: Скрипичные диаграммы + тест Манна–Уитни / Краскела–Уоллиса

Параметры: | Поле | Описание | |-----|-----| | `value` | Числовая переменная | | `group` | Группирующая переменная |

Выводимые метрики:

Метрика	Описание
<code>mann_whitney_p</code>	p-value U-теста (2 группы)
<code>kruskal_p</code>	p-value H-теста (>2 групп)
<code>significant</code>	$p < 0.05$

Графики: Скрипичная диаграмма, опционально с box plot и точками (swarm).

5.7. ANOVA / Kruskal-Wallis

Метод: Однофакторный дисперсионный анализ (ANOVA) или H-тест Краскела–Уоллиса

Параметры: | Поле | Описание | |-----|-----| | `value` | Числовая зависимая переменная | | `group` | Категориальная группирующая (≥ 2 групп) |

Выводимые метрики (вкладки):

Вкладка Statistics:

Метрика	Описание
test_name	ANOVA или Kruskal-Wallis
F_stat / H_stat	Статистика теста
p_value	Уровень значимости
eta_sq	η^2 — доля дисперсии, объяснённая группой (ANOVA)
omega_sq	ω^2 — менее смещённая версия η^2
epsilon_sq	ϵ^2 — мера эффекта для Краскела–Уоллиса
trend_test	Тест Джонкхира–Терпстры (p-value тренда), если ≥ 3 групп

Вкладка Post-hoc:

Метрика	Описание
Попарные сравнения	Tukey HSD (ANOVA) или Mann-Whitney с Бонферрони (KW)
significant	$p < 0.05$ после коррекции

Вкладка Diagnostics:

Метрика	Описание
all_normal	Все группы нормальны (Shapiro-Wilk, $p > 0.05$)
equal_var	Равенство дисперсий (Levene, $p > 0.05$)

Графики: Boxplot + jitter + барплот средних $\pm$ SD.

5.8. Chart Builder

Метод: Быстрая визуализация (без статистических тестов)

Параметры: | Поле | Описание | |-----|-----| |
Chart type | Histogram, Box Plot, Scatter, Bar
(mean $\pm$ SD), Density | | x | Переменная X | | y |
Переменная Y (только scatter) | | group | Цвет/группировка

|| Bins | Число бинов гистограммы (по умолч. 20) || KDE
curve | Наложить кривую плотности (гистограмма) ||
Regression line | Линия регрессии с r^2 (scatter) || Chart
Axes | Настройка заголовка, подписей осей |

Графики: Запрошенный тип графика.

5.9. Cox Regression

Метод: Регрессия пропорциональных рисков Кокса
(lifelines CoxPHFitter)

Параметры: | Поле | Описание | |-----|-----| | event |
Индикатор события (0 = цензурировано, 1 = событие) ||
time | Время до события || covariates | Предикторы ||
Тип ковариаты | Кнопка Cat / Cont — категориальная или
непрерывная || Reference groups | Референтная
категория для категориальных переменных || **Univariate** |
Каждый предиктор отдельно || **Multivariate** | Все
предикторы вместе || **Method** | Enter (все сразу),
Forward (прямой отбор), Backward (обратный отбор) ||
p_enter | p-уровень для включения (по умолч. 0.05) ||
p_remove | p-уровень для удаления (по умолч. 0.10) ||
Adjust Survival Curves | Ковариата для
скорректированных кривых выживаемости |

Выводимые метрики:

Вкладка Table:

Метрика	Описание
Variable	Имя переменной
Beta (β)	Коэффициент регрессии
SE	Стандартная ошибка
z	z-статистика
HR (Hazard Ratio)	$\exp(\beta)$ — отношение рисков; >1 = риск выше, <1 = риск ниже
95% CI	95% доверительный интервал для HR
p-value	Уровень значимости (Вальд-тест)

Вкладка Diagnostics:

Метрика	Описание
C-index	Индекс конкордантности Харрелла — дискриминация модели (0.5 = случайно, 1.0 = идеально). Не калиброван для цензурированных данных
AIC	Информационный критерий Акаике — мера качества модели (меньше = лучше). Не интерпретируется изолированно
BIC	Байесовский информационный критерий — штрафует за сложность сильнее AIC
Log-likelihood	Логарифмическое правдоподобие при сходимости
Global LRT p	p-value теста отношения правдоподобия (вся модель значима, если $p < 0.05$)
Schoenfeld test	Тест пропорциональности рисков. $p < 0.05$ — нарушение допущения PH для данной переменной. Ключевой diagnostic
VIF	Фактор инфляции дисперсии — > 10 = мультиколлинеарность, > 5 = умеренная

Вкладка Steps (для Forward/Backward): история пошагового отбора.

Кнопка "Save Risk" — сохраняет предсказанный риск (линейный предиктор) как новую колонку.

Графики (с чекбоксами, все опционально): - **Forest plot** — HR с 95% CI - **Survival curves** — скорректированные кривые выживаемости - **Residuals** — Martingale residuals (диагностика линейности)

Проверки: - EPV (Events Per Variable) ≥ 10 — предупреждение при < 10 - Schoenfeld — проверка PH для каждой переменной и глобально - VIF — мультиколлинеарность - **Stepwise warning:** p-values не учитывают процесс отбора и могут быть завышены

5.10. Logistic Regression

Метод: Логистическая регрессия с L2-штрафом,
`class_weight='balanced'`

Параметры: | Поле | Описание | |-----|-----| | `target` |
Бинарная целевая переменная | | `predictors` |
Предикторы | | Тип ковариаты | `Cat / Cont` | | `Reference groups` | Референтная категория | | **Univariate** | Каждый предиктор отдельно | | **Multivariate** | Все предикторы вместе | | **Method** | `Enter` , `Forward` , `Backward` | | **Validation** | `None` , `Train/Test (80/20)` , `Cross-val (5-fold CV)` | | **Plots** | Чекбоксы: ROC, DCA, Calibration. Все опционально, выберите нужные |

Выводимые метрики:

Вкладка Table:

Метрика	Описание
<code>Variable</code>	Имя переменной
<code>Beta (β)</code>	Коэффициент регрессии
OR (Odds Ratio)	$\exp(\beta)$ — отношение шансов; >1 = шанс выше, <1 = шанс ниже
<code>95% CI</code>	95% доверительный интервал для OR
<code>p-value</code>	Уровень значимости (Вальд-тест)

Вкладка Diagnostics:

Метрика	Описание
AUC	Площадь под ROC-кривой — дискриминация: 0.5 = случайно, 0.8 = отлично, 1.0 = идеально
Accuracy	$(TP+TN)/(Всего)$ — общая правильность классификации
Sensitivity	$TP/(TP+FN)$ — чувствительность, доля верно предсказанных событий
Specificity	$TN/(TN+FP)$ — специфичность, доля верно предсказанных не-событий
Hosmer-Lemeshow	Тест калибровки: χ^2 , df, p-value. p<0.05 — значимое отклонение от идеальной калибровки
VIF	Мультиколлинеарность (>10 = проблемная)
Warnings	Предупреждения (ошибки VIF, проблемы сходимости)

Вкладка Steps (для Forward/Backward): история пошагового отбора.

Кнопка "Save Probabilities" — сохраняет предсказанные вероятности как новую колонку.

Графики (с чекбоксами, все опционально): - ROC-кривая - DCA (Decision Curve Analysis) - Калибровочная кривая

Проверки: - Цель должна быть бинарной (ровно 2 уникальных значения) - Минимум 20 полных наблюдений - Стандартизация всех предикторов (StandardScaler) -

Предупреждение при validation="none": метрики оптимистичны

5.11. Logistic LASSO

Метод: LASSO-регрессия (L1-регуляризованная логистическая регрессия)

Параметры: | Поле | Описание | |-----|-----| | target | Бинарная цель | | covariates | Предикторы (пусто = все числовые + закодированные категориальные) | | Auto-

`select C` | Автоматический выбор C через 5-fold CV | `C` | Значение C (если авто-выбор отключён). Меньше C = сильнее регуляризация | **Plots** | Чекбоксы: Coef Plot, CV Curve, DCA, Calibration. Все опционально |

Выводимые метрики:

Метрика	Описание
AUC	Площадь под ROC-кривой (на тренировочных данных — оптимистична)
Accuracy	Общая точность (тренировочная — оптимистична)
<code>n_features_selected</code>	Сколько фич осталось с ненулевым коэффициентом
<code>n_features_zeroed</code>	Сколько фич обнулено (удалено LASSO)
<code>best_C</code>	Лучшее значение C (если <code>auto_select</code>)
<code>selected_features</code>	Список: feature, OR, коэффициент
<code>zeroed_features</code>	Список обнулённых фич
<code>intercept</code>	Свободный член модели

Графики (с чекбоксами, все опционально): - Столбчатая диаграмма коэффициентов - Кривая CV (если `auto_select_C`) - DCA (Decision Curve Analysis) - Калибровочная кривая

Проверки: - Метрики на тренировочных данных — **оптимистичны**. Не подходят для оценки генерализации - `class_weight='balanced'` — коррекция дисбаланса классов - `solver='saga'` — подходит для L1-штрафа

5.12. Random Forest

Метод: Случайный лес (sklearn RandomForestClassifier, 200 деревьев, `max_depth=10`, `min_samples_leaf=5`, `class_weight='balanced'`)

Параметры: | Поле | Описание | |-----|-----| | `target` |
Целевая переменная (бинарная или мультикласс) | |
`exclusions` | Исключаемые колонки (через запятую) | |
`Top features` | 10, 15 (по умолч.), 20, All | |
`SHAP analysis` | Включить расчёт SHAP (может быть медленным на большом датасете) |

Выводимые метрики:

Метрика	Описание
OOB score	Out-of-Bag R ² — несмещённая оценка качества на неиспользованных деревьях
Accuracy	Точность на тестовой выборке (75/25 split)
AUC	ROC AUC (только для бинарной цели)
Precision	PPV = TP/(TP+FP)
Recall	Sensitivity = TP/(TP+FN)
F1	Гармоническое среднее Precision и Recall
<code>n_samples</code>	Количество наблюдений
<code>n_features</code>	Количество фич
<code>top_features</code>	Gini importance — вклад фич в уменьшение нечистоты узлов (не путать с p-value!)
<code>shap_features</code>	Среднее абсолютное SHAP — вклад фичи в предсказание (более интерпретируемо)

Графики: - Feature importance (Gini) - SHAP bar plot (если включён) - SHAP summary plot (если включён)

Кнопки после выполнения: - **"Save Model"** — сохраняет модель в .joblib (с метаданными: фичи, цель, метрики) - **"Save Probabilities"** — сохраняет предсказанные вероятности

Проверки: - Авто-исключение колонок: `_event`, `event_`, `_time`, `time_`, `predicted_`, `_prob`, `censored`, `followup`, `cox_`, `logistic_` - 75/25 стратифицированное

разделение - Только числовые предикторы
(категориальные исключаются)

5.13. Kaplan-Meier

Метод: Кривые выживаемости Каплана–Мейера /
кумулятивный риск Нельсона–Аалена

Параметры: | Поле | Описание | |-----|-----| | `time` |
Время до события | | `event` | Индикатор события | | `group` |
| Группирующая переменная | | `stratify` |
Стратифицирующая переменная (анализ по каждой страту
отдельно) | | `Survival / Hazard` | Тип графика:
выживаемость или кумулятивный риск | | `95% CI` |
Показывать доверительные интервалы | | `Chart Axes` |
Шаг по X (мес.), шаг по Y (%), подписи |

Выводимые метрики:

Метрика	Описание
<code>n_total</code>	Всего наблюдений
<code>events_total</code>	Всего событий
<code>summary</code>	По группам: n, events, median (медиана выживаемости в месяцах)
Log-rank p	p-value лог-ранк теста (сравнение групп). $p < 0.05$ = группы различаются
Pairwise log-rank	Попарные сравнения с коррекцией Бонферрони. Показывает, какие именно группы различаются
<code>number_at_risk</code>	Таблица «число под риском» по временным точкам
<code>survival_probability</code>	Таблица вероятностей выживаемости $S(t)$
<code>median_survival</code>	Медиана выживаемости по группам. NR = не достигнута

Графики: - Кривая Каплана–Мейера (S(t)) или Нельсона–Аалена (H(t)) - При стратификации — отдельный график на каждую страту

Проверки: - Хотя бы 1 событие - Стратифицированный анализ — КМ отдельно для каждого уровня страты -

Предупреждение о множественных сравнениях при >2 групп

5.14. ROC Analysis

Метод: ROC-анализ нескольких числовых предикторов vs бинарная цель

Параметры: | Поле | Описание | |-----|-----| | target | Бинарная цель | | Event value | Значение, считающееся событием (1 или 0) | | predictors | Числовые предикторы |

Выводимые метрики:

Вкладка ROC Results:

Метрика	Описание
AUC	Площадь под ROC-кривой с 95% CI (метод Хэнли–МакНейла)
Threshold	Оптимальный порог по индексу Юдена ($J = \text{sens} + \text{spec} - 1$)
Sensitivity	Чувствительность при оптимальном пороге
Specificity	Специфичность при оптимальном пороге
PPV	Положительная прогностическая ценность
NPV	Отрицательная прогностическая ценность

Вкладка Comparison (если ≥ 2 предикторов):

Метрика	Описание
DeLong test	Попарное сравнение AUC ($p < 0.05 = \text{AUC}$ различаются значимо)

Графики: Совмещённые ROC-кривые всех предикторов.

5.15. Model Evaluation (Binary)

Метод: Комплексная оценка бинарной классификации с bootstrap CI

Параметры: | Поле | Описание | |-----|-----| | target | Бинарная цель | | predictors | Колонки с предсказанными вероятностями (0-1) | | Bootstrap samples | 500, 1000 (по умолч.), 2000 | | DCA | Включить Decision Curve Analysis | | Calibration | Включить калибровочные кривые |

Выводимые метрики:

Метрика	Описание
AUC	Площадь под ROC-кривой с bootstrap 95% CI
Accuracy	Общая точность
Sensitivity / Specificity	Чувствительность и специфичность
PPV / NPV	Прогностические ценности
F1	Гармоническое среднее precision и recall
Brier Score	Среднеквадратичная ошибка вероятности. 0 = идеально, <0.25 = хорошо, >0.25 = плохо
DCA Net Benefit	Чистая польза при порогах 5-50%. $NB = (TP/n) - (FP/n) \times (p/(1-p))$
best_model	Модель с наивысшим AUC

Графики: - DCA (Decision Curve Analysis) — все модели на одном графике - Калибровочные кривые (одна на модель)

Проверки: - Авто-инверсия, если AUC < 0.5 - Bootstrap-доверительные интервалы для AUC (перцентильный метод)

5.16. Survival Prediction Evaluation

Метод: Оценка прогностических моделей выживаемости (C-index, time-dependent AUC)

Параметры: | Поле | Описание | |-----|-----| | `time` |
Время до события | | `event` | Индикатор события | |
`predictors` | Колонки с рисками/предсказаниями | |
`Evaluation time points` | Временные точки для AUC
(через запятую, напр. "12,24,48") | | `stratify` |
Стратификация | | `Bootstrap samples` | 500, 1000 (по
умолч.), 2000 | | `Smooth` | Сглаженные кривые AUC |

Выводимые метрики:

Метрика	Описание
C-index	Индекс конкордантности Харрелла с bootstrap 95% CI
Time-dependent AUC	AUC как функция времени (cumulative dynamic AUC)
ΔC (model comparison)	Разница C-index между моделями с bootstrap p-value
Strata	Отдельные результаты для каждого уровня страты

Графики: - Time-dependent AUC plot (опционально сглаженный)

5.17. Diagnostic Accuracy

Метод: Метрики диагностической точности бинарных тестов

Параметры: | Поле | Описание | |-----|-----| | `target` |
Референсный стандарт (золотой стандарт, бинарный) | |
`predictors` | Индексные тесты (бинарные или
вероятности 0-1) |

Выводимые метрики:

Вкладка Test Metrics (на каждый тест):

Метрика	Описание
Sensitivity (95% CI)	$TP/(TP+FN)$ — чувствительность
Specificity (95% CI)	$TN/(TN+FP)$ — специфичность
PPV (95% CI)	$TP/(TP+FP)$ — положительная прогностическая ценность
NPV (95% CI)	$TN/(TN+FN)$ — отрицательная прогностическая ценность
Accuracy (95% CI)	$(TP+TN)/(Total)$ — общая точность
LR+ (95% CI)	Положительное отношение правдоподобия = $Sens/(1-Spec)$. >10 = сильное доказательство
LR- (95% CI)	Отрицательное отношение правдоподобия = $(1-Sens)/Spec$. <0.1 = сильное доказательство
DOR	Diagnostic Odds Ratio = $(TP \times TN)/(FP \times FN)$. 1 = бесполезный тест

Вкладка Comparison (если >1 теста):

Метрика	Описание
McNemar test	Попарное сравнение тестов (чувствительность и специфичность отдельно). $p < 0.05$ = тесты значимо различаются

Вкладка Contingency Tables: Матрицы TP/FP/FN/TN для каждого теста.

Графики: Forest plot чувствительности и специфичности (с 95% CI).

Примечание: Если тест — вероятности (0-1), авто-порог срабатывает при 0.5.

5.18. Agreement Analysis

Метод: Каппа Козна (2 оценщика) / Взвешенная каппа (порядковая) / Каппа Флейсса (3+ оценщика)

Параметры: | Поле | Описание | |-----|-----| |
 predictors | Оценщики (≥ 2 колонок) | | Nominal /
 Ordinal | Тип шкалы | | Linear / Quadratic | Тип весов
 (для порядковой) |

Выводимые метрики:

Метрика	Описание
Карра	Коэффициент каппа — согласие с поправкой на случайное совпадение
95% CI	Доверительный интервал
p-value	Значимость отличия от нуля
Interpretation	Вербальная интерпретация: Poor (≤ 0), Slight (0.01-0.20), Fair (0.21-0.40), Moderate (0.41-0.60), Substantial (0.61-0.80), Almost Perfect (0.81-1.00)
percent_agreement	Процент сырого согласия

Для ≥ 3 оценщиков: Fleiss' Kappa + per-category kappa.

Графики: Тепловая карта (confusion matrix) для 2 оценщиков.

5.19. Individual Prediction

Метод: Предсказание для одного пациента из сохранённой модели

Параметры: | Поле | Описание | |-----|-----| | **Select File** |
 Загрузить .joblib или .pkl модель | | Форма пациента |
 Радиокнопки для категориальных фич, числа для числовых |

Выводимые метрики:

Метрика	Описание
prediction	Предсказанный класс
probability	Вероятность класса 1

Графики: SHAP waterfall plot — вклад каждой фичи в предсказание.

6. AI Chat

6.1. Настройки AI

Кнопка "AI Settings" (левая панель или над AI Chat):

Параметр	Описание
Provider	Ollama (Local) — локальный запуск моделей. Groq (Cloud) — облачный API
Ollama URL	Адрес сервера Ollama (по умолч. http://localhost:11434)
Ollama Model	Модель (загружается после "Test Connection")
Groq API Key	Ключ API (получить на console.groq.com)
Groq Model	Модель (список загружается после "Test Connection")
Temperature	Температура генерации (0 = детерминировано, 1 = креативно). Для анализа: 0.1-0.3, для чата: 0.7
Max Tokens	Максимальная длина ответа (100-8000)
System Prompt	Системный промпт — инструкция AI. Содержит контекст проекта, датасета и до 5 последних анализов (с output_preview и метриками)

Кнопки: - "Test Connection" — проверить связь с провайдером и загрузить список моделей - "Connect" — подтвердить выбор провайдера - "Reset to default" — сбросить системный промпт - **Save / Cancel** — сохранить или отменить настройки

6.2. Режимы: Assistant и Coder

AI Assistant (по умолчанию): - Обычный чат с AI -
Отвечает на вопросы по статистике, интерпретирует

результаты - Имеет контекст проекта и истории анализов -
Поддерживает markdown-форматирование

AI Coder (кнопка "Coder"): - Генерирует Python-код для анализа - Авто-извлекает блоки ````python` и выполняет их - Показывает вывод кода и графики - Пытается исправить ошибки (до 3 попыток) - Использует температуру 0 (детерминированный вывод)

7. Отчёты

Правая панель → вкладка **Reports**.

7.1. Обычный DOCX-отчёт

Параметр	Описание
Analyses	All analyses или Selected (с чекбоксами)
Sections	Dataset overview, Results tables, Key metrics
Title	Заголовок отчёта
Generate DOCX	Создать отчёт. Скачивается по ссылке

Содержимое: - Обзор датасета (число строк, колонок по типам) - Для каждого анализа: метрики, таблицы из output_preview

7.2. AI-отчёт

Параметр	Описание
Language	Язык отчёта (пользовательский ввод, по умолч. "English")
Generate AI Report	Создать отчёт через AI

Содержимое (генерируется AI): 1. **Objective** — на основе контекста проекта 2. **Materials** — описание датасета 3. **Methods** — использованные статистические методы 4. **Results** — ключевые находки с точными числами 5. **Conclusion** — краткое резюме

Требования: - AI должен быть настроен (выбран провайдер, валидные учетные данные) - Выбрано хотя бы несколько анализов (макс. 5)

8. Режим Code Editor

Кнопка **"Code"** в заголовке.

Действие	Описание
Код вводится в текстовое поле (моноширинный шрифт)	
Run	Выполнить код через <code>exes()</code> на сервере
Clear Code	Очистить редактор
Clear History & Plots	Удалить всю историю анализов и графики
Exit Code Mode	Вернуться к анализу

Доступные объекты в коде: - `df` — pandas DataFrame проекта - `pd`, `np`, `plt`, `shap` — стандартные библиотеки - `save_plot(name)` — сохранить график (авто-заккрытие figure) - `fmt_p(p)` — форматирование p-value - `get_label(var, value)` — метки переменных

9. История анализа (Chain)

Правая панель → вкладка **Chain**.

- Хронологический список выполненных анализов (обратный порядок)
- Максимум 200 записей в истории
- Цветовая индикация:
 - **Синий** — регрессия
 - **Зелёный** — выживаемость
 - **Жёлтый** — оценка
 - **Серый** — базовые тесты
 - **Оранжевый** — LASSO
 - **Фиолетовый** — Random Forest / Random Survival Forest

- Клик по элементу — восстановить карточку анализа с результатами

10. Клавиатурные сочетания и советы

Действие	Описание
Enter в поле ввода AI	Отправить сообщение
Shift+Enter	Новая строка
Клик по переменной	Назначить активному полю
Hide Charts	Скрыть графики в карточке (экономит память)
 / 	Сменить тему

Рекомендации по использованию

1. **Начинайте с Descriptive Statistics** — проверьте распределения, пропуски, выбросы
2. **Используйте Categorical + Numeric Comparison** для предварительного анализа
3. **Для регрессии:** начинайте с Univariate, затем Multivariate (Enter), затем Stepwise при необходимости
4. **Проверяйте Schoenfeld PH test** в Cox — это ключевое допущение
5. **VIF > 10** — удалите коллинеарные предикторы
6. **DCA** помогает оценить клиническую пользу модели, а не только статистическую значимость
7. **Bootstrap CI** даёт более реалистичную оценку точности метрик
8. **Не полагайтесь только на Stepwise p-values** — они не учитывают процесс отбора
9. **LASSO** с auto-select C — хороший выбор для отбора фич при большом их числе
10. **AI Coder mode** полезен для быстрых ad-hoc анализов