

PDD_STAT -- Руководство пользователя

Версия: 1.0

Разработчик: П. Демешко

Язык интерфейса: английский (метки, выводы результатов -- на английском)

Содержание

1. [Обзор системы](#1-обзор-системы)
 2. [Установка и запуск](#2-установка-и-запуск)
 3. [Управление проектами и данными](#3-управление-проектами-и-данными)
 - 3.1. Создание проекта и загрузка данных
 - 3.2. Очистка данных
 - 3.3. Управление переменными
 - 3.4. Контекст проекта (описание, цель)
 4. [Интерфейс](#4-интерфейс)
 - 4.1. Левая панель -- Project Manager
 - 4.2. Рабочая область
 - 4.3. Правая панель -- Variables
 5. [Шаблоны статистического анализа](#5-шаблоны-статистического-анализа)
 - 5.1. Categorical Comparison -- Сравнение категориальных переменных
 - 5.2. Numeric Comparison -- Сравнение числовых переменных
 - 5.3. Correlation Analysis -- Корреляционный анализ
 - 5.4. Spline Analysis -- Сплайн-анализ
 - 5.5. Descriptive Statistics -- Описательная статистика
 - 5.6. Violin Plots -- Скрипичные диаграммы
 - 5.7. ANOVA / Kruskal-Wallis -- Дисперсионный анализ
 - 5.8. Chart Builder -- Построитель графиков
 - 5.9. Cox Regression -- Регрессия Кокса
 - 5.10. Logistic Regression -- Логистическая регрессия
 - 5.11. Logistic LASSO -- LASSO-регрессия
 - 5.12. Random Forest -- Случайный лес
 - 5.13. Kaplan-Meier -- Кривые Каплана-Мейера
 - 5.14. ROC Analysis -- ROC-анализ
 - 5.15. Model Evaluation (Binary) -- Оценка бинарной модели
 - 5.16. Survival Prediction Evaluation -- Оценка прогнозов выживаемости
 - 5.17. Diagnostic Accuracy -- Диагностическая точность
 - 5.18. Agreement Analysis -- Анализ согласия
 - 5.19. Individual Prediction -- Индивидуальный прогноз
 6. [AI Chat](#6-ai-chat)
 - 6.1. Настройки AI
 - 6.2. Режимы: Assistant и Coder
 7. [Отчёты](#7-отчёты)
 - 7.1. Обычный DOCX-отчёт
 - 7.2. AI-отчёт
 8. [Режим Code Editor](#8-режим-code-editor)
 9. [История анализа (Chain)](#9-история-анализа-chain)
 10. [Клавиатурные сочетания и советы](#10-клавиатурные-сочетания-и-советы)
-

1. Обзор системы

PDD_STAT -- веб-приложение для статистического анализа медицинских и клинических данных. Система предоставляет:

- 22 шаблона статистического анализа (от описательной статистики до регрессионных моделей и анализа выживаемости)
- AI-ассистента на базе Ollama (локально) или Groq (облачный API)
- Генерацию отчётов в формате DOCX (обычный и AI-сгенерированный)
- Редактор кода для произвольного Python-анализа
- Визуализацию: графики matplotlib, SHAP, DCA, калибровочные кривые

Ключевые возможности

- Все выводы -- на английском языке (метрики, таблицы, подписи графиков)
- Защита от статистических ошибок: проверка пропорциональных рисков (Schoenfeld), мультиколлинеарности (VIF), нормальности, гомогенности дисперсий, калибровки (Hosmer-Lemeshow)
- Коррекция на множественные сравнения (Бонферрони) в попарных тестах
- Стратифицированный анализ для выживаемости
- Пошаговый отбор (stepwise) предикторов с контролем p-уровня
- DCA (Decision Curve Analysis) и калибровочные кривые для регрессионных моделей
- Bootstrap для доверительных интервалов метрик
- SHAP для интерпретации моделей Random Forest

2. Установка и запуск

Требования

Компонент	Версия
Python	≥ 3.9
pip	≥ 21.0

Установка зависимостей

```
cd app/backend
pip install -r requirements.txt
```

Запуск

```
cd app/backend
python3 -m uvicorn app.main:app --host 127.0.0.1 --port 8000
```

Откройте браузер по адресу: <http://127.0.0.1:8000>

Фронтенд не требует отдельной сборки -- сервер раздаёт статические файлы (app/frontend/) автоматически.

3. Управление проектами и данными

3.1. Создание проекта и загрузка данных

1. Нажмите "Create Project" (левая панель).
2. Введите название проекта (латиница или кириллица).
3. Выберите файл с данными:
 - Поддерживаемые форматы: .xlsx, .xls, .csv
4. Нажмите "Create".
5. После загрузки появится окно Cleaning Recommendations (см. раздел 3.2).

Повторная загрузка в существующий проект: нажмите на название проекта левой кнопкой -- откроется диалог выбора файла.

3.2. Очистка данных

При загрузке данных система автоматически анализирует каждую колонку и предлагает план очистки:

Удаляемые колонки

Правило	Условие	Уровень
HIGH_MISSING	>30% пропущенных значений	Жёсткое
MODERATE_MISSING	20–30% пропущенных	Мягкое
CONSTANT	только 1 уникальное значение	Жёсткое
IDENTIFIER	все значения уникальны (n>10)	Жёсткое
TECHNICAL	имя начинается с `INFO_`, `CHECK_`, `PARAMS_` и т.д.	Жёсткое

Импутация

Остальные колонки с пропусками:

- Числовые → заполняются медианой
- Категориальные/строковые → заполняются модой

Кнопки:

- "Apply Cleaning" -- применить очистку
- "Skip (Keep as is)" -- сохранить данные как есть

После очистки данные сохраняются в `state/project_data.parquet` (сжатие `snappy`).

3.3. Управление переменными

Правая панель → вкладка "Columns":

- Поиск по названию переменной
- Тип переменной отображается бейджем:
 - `num` -- числовая
 - `cat` -- категориальная
 - `bin` -- бинарная
 - `str` -- строковая
- Действия с переменной:
 - -- переименовать
 - -- удалить из датасета
 - -- открыть окно меток (Label):
- Chart Name -- отображаемое имя на графиках
- Value Labels -- метки значений (например, 0 = Нет, 1 = Да)

Быстрый выбор переменной: клик по имени переменной присваивает её активному полю в карточке анализа (поле подсвечивается цветом).

3.4. Контекст проекта (описание, цель)

Кнопка на элементе проекта → Project Context:

- Description -- описание проекта (используется AI для контекста)
- Research Aim -- цель исследования
- Notes -- дополнительные заметки

Контекст автоматически включается в системный промпт AI-ассистента и в AI-отчёты.

4. Интерфейс

4.1. Левая панель -- Project Manager

Элемент	Описание
+ Create Project	Создать новый проект
Список проектов	Имена проектов. Клик — открыть/загрузить данные. — контекст. — удалить
AI Settings	Настройки AI-ассистента
	Свернуть/развернуть панель

4.2. Рабочая область

Центральная область -- контейнер для карточек анализа (см. раздел 5).

Меню выбора шаблонов (верхняя панель):

Меню	Шаблоны
**Basic Stats **	Categorical, Numeric, Correlation, Spline, Descriptive, Violin, ANOVA, Chart Builder
**Regression **	Cox, Logistic, LASSO, Random Forest
**Survival **	Kaplan-Meier
**Evaluation **	Model Evaluation (Binary), Survival Eval, ROC, Diagnostic Accuracy, Agreement
**Prediction **	Individual Prediction

Кнопки:

- AI Chat -- открыть чат с AI-ассистентом
- Code -- перейти в режим редактора кода
- / -- переключение светлой/тёмной темы

4.3. Правая панель -- Variables

Вкладка	Содержимое
Columns	Список переменных с поиском, типами, редактированием
Reports	Генерация отчётов DOCX
Chain	История выполненных анализов

5. Шаблоны статистического анализа

5.1. Categorical Comparison

Метод: χ^2 -тест / Точный тест Фишера / Монте-Карло

Параметры:

Поле	Описание
`col1`	Первая категориальная переменная (строки таблицы)
`col2`	Вторая категориальная переменная (столбцы таблицы)

Логика выбора теста:

1. Если все ожидаемые частоты $\geq 5 \rightarrow \chi^2$ -тест
2. Если низкие ожидаемые И таблица $2 \times 2 \rightarrow$ Точный тест Фишера
3. Иначе $\rightarrow$ Монте-Карло (10 000 итераций)

Выводимые метрики:

Метрика	Описание
`chi2`	Статистика χ^2
`p_value`	Уровень значимости
`df`	Число степеней свободы
`min_expected_frequency`	Минимальная ожидаемая частота
`all_expected_ge5`	Все ожидаемые ≥ 5 ?
`odds_ratio`	Отношение шансов (только для Fisher, 2×2)
`significant`	$p < 0.05$

Интерпретация p-value:

- $p < 0.05$ -- есть статистически значимая связь между переменными
- $p \geq 0.05$ -- нет оснований отвергать гипотезу о независимости

5.2. Numeric Comparison

Метод: t-тест (независимый) / ANOVA (параметрический) или U-тест Манна-Уитни / H-тест Краскела-Уоллиса (непараметрический)

Параметры:

Поле	Описание
`value`	Числовая зависимая переменная
`group`	Категориальная группирующая переменная

Логика выбора теста:

- Если нормальность (Shapiro-Wilk) И гомогенность дисперсий (Levene):
- 2 группы → t-тест + d Козна
- >2 групп → ANOVA + η^2
- Иначе:
- 2 группы → U-тест Манна-Уитни
- >2 групп → H-тест Краскела-Уоллиса

Выводимые метрики:

Метрика	Описание
`test_name`	Название применённого теста
`statistic`	Значение тестовой статистики
`p_value`	Уровень значимости
`cohens_d`	d Козна (для t-теста) — мера эффекта
`normality`	Результаты теста Шапиро–Уилка по группам
`equal_var`	Гомогенность дисперсий (Levene)
`descriptive_stats`	Описательные статистики по группам (n, median, Q1, Q3)

Графики: Boxplot + барплот (среднее ± SD), 2 панели.

5.3. Correlation Analysis

Метод: Корреляция Пирсона (параметрическая) или Спирмена (ранговая)

Параметры:

Поле	Описание
`predictors`	Выбор нескольких переменных
`method`	`Pearson` (для нормальных данных) или `Spearman` (для любых)
`threshold`	Порог

Выводимые метрики:

Метрика	Описание
`method`	Метод корреляции
`n_variables`	Количество переменных
`n_strong_pairs`	Пар с
`strongest_r`	Максимальный
`strongest_pair`	Пара с макс.
`pairs`	Список сильных пар: var1, var2, r, **скорректированный p** (Бонферрони)

p-value корректируется по методу Бонферрони (умножается на число всех попарных тестов), что контролирует семейную ошибку первого рода (FWER).

Графики: Тепловая карта корреляционной матрицы (нижний треугольник).

5.4. Spline Analysis

Метод: Линейный сплайн-анализ в рамках Cox-регрессии или логистической регрессии

Параметры:

Поле	Описание
`variable`	Переменная для сплайна
`target`	(для логистики) Бинарный исход
`time` + `event`	(для Cox) Время + событие
`covariates`	Ковариаты для коррекции
`knots`	Расположение узлов: `Median`, `Quartiles`, `Custom` + число

Выводимые метрики:

Метрика	Описание
`model_type`	`spline_cox` или `spline_logistic`
`knots`	Позиции узлов сплайна
`nonlinear_p`	p-value теста нелинейности — проверяет, значимо ли отклонение от линейности

Метрика	Описание
`significant_nonlinear`	$p < 0.05 \rightarrow$ есть нелинейный эффект

Графики: Log-HR / Log-OR vs переменная с узлами (левая панель) + гистограмма переменной с узлами (правая панель).

5.5. Descriptive Statistics

Метод: Описательные статистики + тест Шапиро-Уилка

Параметры:

Поле/Опция	Описание
`covariates`	Переменные (пусто = все числовые)
`Include histograms`	Гистограммы для каждой переменной

Выводимые метрики:

- N, Mean, Median, Std, Min, Max, Q1, Q3
- Skewness (асимметрия), Kurtosis (экссесс)
- Missing count (количество пропусков)
- Outlier count (количество выбросов по методу IQR -- за пределы $Q1 - 1.5 \times IQR$ / $Q3 + 1.5 \times IQR$)
- Shapiro-Wilk W и p-value (нормальность; $p < 0.05$ = распределение отличается от нормального)

5.6. Violin Plots

Метод: Скрипичные диаграммы + тест Манна-Уитни / Краскела-Уоллиса

Параметры:

Поле	Описание
`value`	Числовая переменная
`group`	Группирующая переменная

Выводимые метрики:

Метрика	Описание
`mann_whitney_p`	p-value U-теста (2 группы)
`kruskal_p`	p-value H-теста (>2 групп)
`significant`	$p < 0.05$

Графики: Скрипичная диаграмма, опционально с box plot и точками (swarm).

5.7. ANOVA / Kruskal-Wallis

Метод: Однофакторный дисперсионный анализ (ANOVA) или H-тест Краскела-Уоллиса

Параметры:

Поле	Описание
`value`	Числовая зависимая переменная
`group`	Категориальная группирующая (≥ 2 групп)

Выводимые метрики (вкладки):

Вкладка Statistics:

Метрика	Описание
`test_name`	`ANOVA` или `Kruskal-Wallis`
`F_stat` / `H_stat`	Статистика теста
`p_value`	Уровень значимости
`eta_sq`	η^2 — доля дисперсии, объяснённая группой (ANOVA)
`omega_sq`	ω^2 — менее смещённая версия η^2
`epsilon_sq`	ε^2 — мера эффекта для Краскела-Уоллиса
`trend_test`	Тест Джонкхира-Терпстры (p-value тренда), если ≥ 3 групп

Вкладка Post-hoc:

Метрика	Описание
---------	----------

Метрика	Описание
Попарные сравнения	Tukey HSD (ANOVA) или Mann-Whitney с Бонферрони (KW)
`significant`	$p < 0.05$ после коррекции

Вкладка Diagnostics:

Метрика	Описание
`all_normal`	Все группы нормальны (Shapiro-Wilk, $p > 0.05$)
`equal_var`	Равенство дисперсий (Levene, $p > 0.05$)

Графики: Boxplot + jitter + барплот средних $\pm$ SD.

5.8. Chart Builder

Метод: Быстрая визуализация (без статистических тестов)

Параметры:

Поле	Описание
`Chart type`	`Histogram`, `Box Plot`, `Scatter`, `Bar (mean $\pm$ SD)`, `Density`
`x`	Переменная X
`y`	Переменная Y (только scatter)
`group`	Цвет/группировка
`Bins`	Число бинов гистограммы (по умолч. 20)
`KDE curve`	Наложить кривую плотности (гистограмма)
`Regression line`	Линия регрессии с r^2 (scatter)
`Chart Axes`	Настройка заголовка, подписей осей

Графики: Запрошенный тип графика.

5.9. Cox Regression

Метод: Регрессия пропорциональных рисков Кокса (lifelines CoxPHFitter)

Параметры:

Поле	Описание
`event`	Индикатор события (0 = цензурировано, 1 = событие)
`time`	Время до события
`covariates`	Предикторы
Тип ковариаты	Кнопка `Cat`/`Cont` — категориальная или непрерывная
`Reference groups`	Референтная категория для категориальных переменных
Univariate	Каждый предиктор отдельно
Multivariate	Все предикторы вместе
Method	`Enter` (все сразу), `Forward` (прямой отбор), `Backward` (обратный отбор)
`p_enter`	p-уровень для включения (по умолч. 0.05)
`p_remove`	p-уровень для удаления (по умолч. 0.10)
`Adjust Survival Curves`	Ковариата для скорректированных кривых выживаемости

Выводимые метрики:

Вкладка Table:

Метрика	Описание
`Variable`	Имя переменной
`Beta ( $\beta$ )`	Коэффициент регрессии
`SE`	Стандартная ошибка
`z`	z-статистика
HR (Hazard Ratio)	$\exp(\beta)$ — отношение рисков; >1 = риск выше, <1 = риск ниже
`95% CI`	95% доверительный интервал для HR
`p-value`	Уровень значимости (Вальд-тест)

Вкладка Diagnostics:

Метрика	Описание
C-index	Индекс конкордантности Харрелла — дискриминация модели (0.5 = случайно, 1.0 = идеально). Не калибр
AIC	Информационный критерий Акаике — мера качества модели (меньше = лучше). Не интерпретируется изо
BIC	Байесовский информационный критерий — штрафует за сложность сильнее AIC

Метрика	Описание
Log-likelihood	Логарифмическое правдоподобие при сходимости
Global LRT p	p-value теста отношения правдоподобия (вся модель значима, если $p < 0.05$)
Schoenfeld test	Тест пропорциональности рисков. **$p < 0.05$** — нарушение допущения PH для данной переменной. Ключе
VIF	Фактор инфляции дисперсии — **> 10** = мультиколлинеарность, **> 5** = умеренная

Вкладка Steps (для Forward/Backward): история пошагового отбора.

Кнопка "Save Risk" -- сохраняет предсказанный риск (линейный предиктор) как новую колонку.

Графики:

- Forest plot (HR с 95% CI)
- Baseline hazard / survival function
- Martingale residuals (диагностика линейности для первого предиктора)
- Скорректированные кривые выживаемости (если выбрана ковариата)

Проверки:

- EPV (Events Per Variable) ≥ 10 -- предупреждение при < 10
- Schoenfeld -- проверка PH для каждой переменной и глобально
- VIF -- мультиколлинеарность
- Stepwise warning: p-values не учитывают процесс отбора и могут быть завышены

5.10. Logistic Regression

Метод: Логистическая регрессия с L2-штрафом, `class_weight='balanced'`

Параметры:

Поле	Описание
<code>`target`</code>	Бинарная целевая переменная
<code>`predictors`</code>	Предикторы
Тип ковариаты	<code>`Cat` / `Cont`</code>
<code>`Reference groups`</code>	Референтная категория
Univariate	Каждый предиктор отдельно
Multivariate	Все предикторы вместе
Method	<code>`Enter`</code> , <code>`Forward`</code> , <code>`Backward`</code>
Validation	<code>`None`</code> , <code>`Train/Test`</code> (80/20), <code>`Cross-val`</code> (5-fold CV)

Выводимые метрики:

Вкладка Table:

Метрика	Описание
<code>`Variable`</code>	Имя переменной
<code>`Beta (<math>\beta</math>)`</code>	Коэффициент регрессии
OR (Odds Ratio)	$\exp(\beta)$ — отношение шансов; > 1 = шанс выше, < 1 = шанс ниже
<code>`95% CI`</code>	95% доверительный интервал для OR
<code>`p-value`</code>	Уровень значимости (Вальд-тест)

Вкладка Diagnostics:

Метрика	Описание
AUC	Площадь под ROC-кривой — дискриминация: 0.5 = случайно, 0.8 = отлично, 1.0 = идеально
Accuracy	$(TP+TN)/(Всего)$ — общая правильность классификации
Sensitivity	$TP/(TP+FN)$ — чувствительность, доля верно предсказанных событий
Specificity	$TN/(TN+FP)$ — специфичность, доля верно предсказанных не-событий
Hosmer-Lemeshow	Тест калибровки: χ^2 , df, p-value. **$p < 0.05$** — значимое отклонение от идеальной калибровки
VIF	Мультиколлинеарность (> 10 = проблемная)
Warnings	Предупреждения (ошибки VIF, проблемы сходимости)

Вкладка Steps (для Forward/Backward): история пошагового отбора.

Кнопка "Save Probabilities" -- сохраняет предсказанные вероятности как новую колонку.

Графики (3):

- ROC-кривая

- DCA (Decision Curve Analysis) с линиями "Treat All" и "Treat None"
- Калибровочная кривая с Brier Score

Проверки:

- Цель должна быть бинарной (ровно 2 уникальных значения)
- Минимум 20 полных наблюдений
- Стандартизация всех предикторов (StandardScaler)
- Предупреждение при validation="none": метрики оптимистичны

5.11. Logistic LASSO

Метод: LASSO-регрессия (L1-регуляризованная логистическая регрессия)

Параметры:

Поле	Описание
`target`	Бинарная цель
`covariates`	Предикторы (пусто = все числовые + закодированные категориальные)
`Auto-select C`	Автоматический выбор C через 5-fold CV
`C`	Значение C (если авто-выбор отключён). Меньше C = сильнее регуляризация

Выводимые метрики:

Метрика	Описание
AUC	Площадь под ROC-кривой (на тренировочных данных — оптимистична)
Accuracy	Общая точность (тренировочная — оптимистична)
`n_features_selected`	Сколько фич осталось с ненулевым коэффициентом
`n_features_zeroed`	Сколько фич обнулено (удалено LASSO)
`best_C`	Лучшее значение C (если auto_select)
`selected_features`	Список: feature, OR, коэффициент
`zeroed_features`	Список обнулённых фич
`intercept`	Свободный член модели

Графики (4):

- Столбчатая диаграмма коэффициентов отобранных фич (дополнительно топ-30 всех)
- Кривая CV (если auto_select_C)
- DCA (Decision Curve Analysis)
- Калибровочная кривая

Проверки:

- Метрики на тренировочных данных -- оптимистичны. Не подходят для оценки генерализации
- class_weight='balanced' -- коррекция дисбаланса классов
- solver='saga' -- подходит для L1-штрафа

5.12. Random Forest

Метод: Случайный лес (sklearn RandomForestClassifier, 200 деревьев, max_depth=10, min_samples_leaf=5, class_weight='balanced')

Параметры:

Поле	Описание
`target`	Целевая переменная (бинарная или мультикласс)
`exclusions`	Исключаемые колонки (через запятую)
`Top features`	10, 15 (по умолч.), 20, All
`SHAP analysis`	Включить расчёт SHAP (может быть медленным)

Выводимые метрики:

Метрика	Описание
OOB score	Out-of-Bag R ² — несмещённая оценка качества на неиспользованных деревьях
Accuracy	Точность на тестовой выборке (75/25 split)
AUC	ROC AUC (только для бинарной цели)
Precision	PPV = TP/(TP+FP)

Метрика	Описание
Recall	Sensitivity = TP/(TP+FN)
F1	Гармоническое среднее Precision и Recall
<code>`n_samples`</code>	Количество наблюдений
<code>`n_features`</code>	Количество фич
<code>`top_features`</code>	Gini importance — вклад фич в уменьшение нечистоты узлов (не путать с p-value!)
<code>`shap_features`</code>	Среднее абсолютное SHAP — вклад фичи в предсказание (более интерпретируемо)

Графики:

- Feature importance (Gini)
- SHAP bar plot (если включён)
- SHAP summary plot (если включён)

Кнопки после выполнения:

- "Save Model" -- сохраняет модель в .joblib (с метаданными: фичи, цель, метрики)
- "Save Probabilities" -- сохраняет предсказанные вероятности

Проверки:

- Авто-исключение колонок: `_event`, `event_`, `_time`, `time_`, `predicted_`, `_prob`, `censored`, `followup`, `cox_`, `logistic_`
- 75/25 стратифицированное разделение
- Только числовые предикторы (категориальные исключаются)

5.13. Kaplan-Meier

Метод: Кривые выживаемости Каплана-Мейера / кумулятивный риск Нельсона-Аалена

Параметры:

Поле	Описание
<code>`time`</code>	Время до события
<code>`event`</code>	Индикатор события
<code>`group`</code>	Группирующая переменная
<code>`stratify`</code>	Стратифицирующая переменная (анализ по каждой страте отдельно)
<code>`Survival` / `Hazard`</code>	Тип графика: выживаемость или кумулятивный риск
<code>`95% CI`</code>	Показывать доверительные интервалы
<code>`Chart Axes`</code>	Шаг по X (мес.), шаг по Y (%), подписи

Выводимые метрики:

Метрика	Описание
<code>`n_total`</code>	Всего наблюдений
<code>`events_total`</code>	Всего событий
<code>`summary`</code>	По группам: n, events, median (медиана выживаемости в месяцах)
Log-rank p	p-value лог-ранк теста (сравнение групп). p<0.05 = группы различаются
Pairwise log-rank	Попарные сравнения с коррекцией Бонферрони. Показывает, какие именно группы различаются
<code>`number_at_risk`</code>	Таблица «число под риском» по временным точкам
<code>`survival_probability`</code>	Таблица вероятностей выживаемости S(t)
<code>`median_survival`</code>	Медиана выживаемости по группам. `NR` = не достигнута

Графики:

- Кривая Каплана-Мейера (S(t)) или Нельсона-Аалена (H(t))
- При стратификации -- отдельный график на каждую страту

Проверки:

- Хотя бы 1 событие
- Стратифицированный анализ -- КМ отдельно для каждого уровня страты
- Предупреждение о множественных сравнениях при >2 групп

5.14. ROC Analysis

Метод: ROC-анализ нескольких числовых предикторов vs бинарная цель

Параметры:

Поле	Описание
`target`	Бинарная цель
`Event value`	Значение, считающееся событием (1 или 0)
`predictors`	Числовые предикторы

Выводимые метрики:

Вкладка ROC Results:

Метрика	Описание
AUC	Площадь под ROC-кривой с 95% CI (метод Хэнли–МакНейла)
`Threshold`	Оптимальный порог по индексу Юдена ($J = \text{sens} + \text{spec} - 1$)
`Sensitivity`	Чувствительность при оптимальном пороге
`Specificity`	Специфичность при оптимальном пороге
PPV	Положительная прогностическая ценность
NPV	Отрицательная прогностическая ценность

Вкладка Comparison (если ≥ 2 предикторов):

Метрика	Описание
DeLong test	Попарное сравнение AUC ($p < 0.05$ = AUC различаются значимо)

Графики: Совмещённые ROC-кривые всех предикторов.

5.15. Model Evaluation (Binary)

Метод: Комплексная оценка бинарной классификации с bootstrap CI

Параметры:

Поле	Описание
`target`	Бинарная цель
`predictors`	Колонки с предсказанными вероятностями (0-1)
`Bootstrap samples`	500, 1000 (по умолч.), 2000
`DCA`	Включить Decision Curve Analysis
`Calibration`	Включить калибровочные кривые

Выводимые метрики:

Метрика	Описание
AUC	Площадь под ROC-кривой с bootstrap 95% CI
`Accuracy`	Общая точность
`Sensitivity` / `Specificity`	Чувствительность и специфичность
PPV / **NPV**	Прогностические ценности
F1	Гармоническое среднее precision и recall
Brier Score	Среднеквадратичная ошибка вероятности. 0 = идеально, < 0.25 = хорошо, > 0.25 = плохо
DCA Net Benefit	Чистая польза при порогах 5-50%. $NB = (TP/n) - (FP/n) \times (p/(1-p))$
`best_model`	Модель с наивысшим AUC

Графики:

- DCA (Decision Curve Analysis) -- все модели на одном графике
- Калибровочные кривые (одна на модель)

Проверки:

- Авто-инверсия, если $AUC < 0.5$
- Bootstrap-доверительные интервалы для AUC (перцентильный метод)

5.16. Survival Prediction Evaluation

Метод: Оценка прогностических моделей выживаемости (C-index, time-dependent AUC)

Параметры:

Поле	Описание
`time`	Время до события
`event`	Индикатор события
`predictors`	Колонки с рисками/предсказаниями

Поле	Описание
`Evaluation time points`	Временные точки для AUC (через запятую, напр. "12,24,48")
`stratify`	Стратификация
`Bootstrap samples`	500, 1000 (по умолч.), 2000
`Smooth`	Сглаженные кривые AUC

Выводимые метрики:

Метрика	Описание
C-index	Индекс конкордантности Харрелла с bootstrap 95% CI
Time-dependent AUC	AUC как функция времени (cumulative dynamic AUC)
ΔC (model comparison)	Разница C-index между моделями с bootstrap p-value
Strata	Отдельные результаты для каждого уровня страты

Графики:

- Time-dependent AUC plot (опционально сглаженный)

5.17. Diagnostic Accuracy

Метод: Метрики диагностической точности бинарных тестов

Параметры:

Поле	Описание
`target`	Референсный стандарт (золотой стандарт, бинарный)
`predictors`	Индексные тесты (бинарные или вероятности 0-1)

Выводимые метрики:

Вкладка Test Metrics (на каждый тест):

Метрика
Sensitivity (95% CI)
Specificity (95% CI)
PPV (95% CI)
NPV (95% CI)
Accuracy (95% CI)
LR+ (95% CI)
LR- (95% CI)
DOR

Вкладка Comparison (если >1 теста):

Метрика	Описание
McNemar test	Попарное сравнение тестов (чувствительность и специфичность отдельно). $p < 0.05$ = тесты значимо различ

Вкладка Contingency Tables: Матрицы TP/FP/FN/TN для каждого теста.

Графики: Forest plot чувствительности и специфичности (с 95% CI).

Примечание: Если тест -- вероятности (0-1), авто-порог срабатывает при 0.5.

5.18. Agreement Analysis

Метод: Каппа Козна (2 оценщика) / Взвешенная каппа (порядковая) / Каппа Флейсса (3+ оценщика)

Параметры:

Поле	Описание
`predictors`	Оценщики (≥ 2 колонок)
`Nominal` / `Ordinal`	Тип шкалы
`Linear` / `Quadratic`	Тип весов (для порядковой)

Выводимые метрики:

Метрика	Описание
Каппа	Кoeffициент каппа — согласие с поправкой на случайное совпадение
`95% CI`	Доверительный интервал
`p-value`	Значимость отличия от нуля

Метрика	Описание
Interpretation	Вербальная интерпретация: Poor (≤ 0), Slight (0.01-0.20), Fair (0.21-0.40), Moderate (0.41-0.60), Substantial (0.61-0.80), Excellent (≥ 0.81)
`percent_agreement`	Процент сырого согласия

Для ≥ 3 оценщиков: Fleiss' Kappa + per-category kappa.

Графики: Тепловая карта (confusion matrix) для 2 оценщиков.

5.19. Individual Prediction

Метод: Предсказание для одного пациента из сохранённой модели

Параметры:

Поле	Описание
Select File	Загрузить .joblib или .pkl модель
Форма пациента	Радиокнопки для категориальных фич, числа для числовых

Выводимые метрики:

Метрика	Описание
`prediction`	Предсказанный класс
`probability`	Вероятность класса 1

Графики: SHAP waterfall plot -- вклад каждой фичи в предсказание.

6. AI Chat

6.1. Настройки AI

Кнопка "AI Settings" (левая панель или над AI Chat):

Параметр	Описание
Provider	`Ollama (Local)` — локальный запуск моделей. `Groq (Cloud)` — облачный API
Ollama URL	Адрес сервера Ollama (по умолч. `http://localhost:11434`)
Ollama Model	Модель (загружается после "Test Connection")
Groq API Key	Ключ API (получить на console.groq.com)
Groq Model	Модель (список загружается после "Test Connection")
Temperature	Температура генерации (0 = детерминировано, 1 = креативно). Для анализа: 0.1-0.3, для чата: 0.7
Max Tokens	Максимальная длина ответа (100-8000)
System Prompt	Системный промпт — инструкция AI. Содержит контекст проекта, датасета и историю анализов

Кнопки:

- "Test Connection" -- проверить связь с провайдером и загрузить список моделей
- "Connect" -- подтвердить выбор провайдера
- "Reset to default" -- сбросить системный промпт
- Save / Cancel -- сохранить или отменить настройки

6.2. Режимы: Assistant и Coder

AI Assistant (по умолчанию):

- Обычный чат с AI
- Отвечает на вопросы по статистике, интерпретирует результаты
- Имеет контекст проекта и истории анализов
- Поддерживает markdown-форматирование

AI Coder (кнопка "Coder"):

- Генерирует Python-код для анализа
- Авто-извлекает блоки `python` и выполняет их
- Показывает вывод кода и графики
- Пытается исправить ошибки (до 3 попыток)
- Использует температуру 0 (детерминированный вывод)

7. Отчёты

Правая панель → вкладка Reports.

7.1. Обычный DOCX-отчёт

Параметр	Описание
Analyses	`All analyses` или `Selected` (с чекбоксами)
Sections	Dataset overview, Results tables, Key metrics
Title	Заголовок отчёта
Generate DOCX	Создать отчёт. Скачивается по ссылке

Содержимое:

- Обзор датасета (число строк, колонок по типам)
- Для каждого анализа: метрики, таблицы из `output_preview`

7.2. AI-отчёт

Параметр	Описание
Language	Язык отчёта (пользовательский ввод, по умолч. "English")
Generate AI Report	Создать отчёт через AI

Содержимое (генерируется AI):

1. Objective -- на основе контекста проекта
2. Materials -- описание датасета
3. Methods -- использованные статистические методы
4. Results -- ключевые находки с точными числами
5. Conclusion -- краткое резюме

Требования:

- AI должен быть настроен (выбран провайдер, валидные учетные данные)
- Выбрано хотя бы несколько анализов (макс. 5)

8. Режим Code Editor

Кнопка "Code" в заголовке.

Действие	Описание
Код вводится в текстовое поле (моноширинный шрифт)	
Run	Выполнить код через <code>`exec()`</code> на сервере
Clear Code	Очистить редактор
Clear History & Plots	Удалить всю историю анализов и графики
Exit Code Mode	Вернуться к анализу

Доступные объекты в коде:

- `df` -- pandas DataFrame проекта
- `pd`, `np`, `plt` -- стандартные библиотеки
- `save_plot(name)` -- сохранить график (авто-заккрытие figure)
- `fmt_p(p)` -- форматирование p-value
- `get_label(var, value)` -- метки переменных

9. История анализа (Chain)

Правая панель → вкладка Chain.

- Хронологический список выполненных анализов (обратный порядок)
- Цветовая индикация:
- Синий -- регрессия
- Зелёный -- выживаемость

- Жёлтый -- оценка
- Серый -- базовые тесты
- Фиолетовый -- Random Forest
- Клик по элементу -- восстановить карточку анализа с результатами

10. Клавиатурные сочетания и советы

Действие	Описание
Enter в поле ввода AI	Отправить сообщение
Shift+Enter	Новая строка
Клик по переменной	Назначить активному полю
Hide Charts	Скрыть графики в карточке (экономит память)
** / **	Сменить тему

Рекомендации по использованию

1. Начинайте с Descriptive Statistics -- проверьте распределения, пропуски, выбросы
2. Используйте Categorical + Numeric Comparison для предварительного анализа
3. Для регрессии: начинайте с Univariate, затем Multivariate (Enter), затем Stepwise при необходимости
4. Проверяйте Schoenfeld PH test в Cox -- это ключевое допущение
5. $VIF > 10$ -- удалите коллинеарные предикторы
6. DCA помогает оценить клиническую пользу модели, а не только статистическую значимость
7. Bootstrap CI даёт более реалистичную оценку точности метрик
8. Не полагайтесь только на Stepwise p-values -- они не учитывают процесс отбора
9. LASSO с auto-select C -- хороший выбор для отбора фич при большом их числе
10. AI Coder mode полезен для быстрых ad-hoc анализов